

UNIVERSIDADE FEDERAL DE ALFENAS - UNIFAL
CIÊNCIA DA COMPUTAÇÃO

CLASSIFICAÇÃO DE TUMORES CEREBRAIS EM IMAGENS DE RESSONÂNCIA MAGNÉTICA UTILIZANDO TRANSFERÊNCIA DE APRENDIZADO

Uma análise comparativa de desempenho, eficiência computacional e explicabilidade

PEDRO BRASSI LUCCAS

Projeto de Pesquisa apresentado como requisito parcial para desenvolvimento do Trabalho de Conclusão de Curso, no curso de Ciência da Computação da Universidade Federal de Alfenas.

Orientador: Professor Doutor Luiz Eduardo da Silva

ALFENAS - MG

2026

Sumário

Resumo

1. Problemática

2. Justificativa

3. Objetivos

3.1. Objetivo geral

3.2. Objetivos específicos

4. Metodologia

5. Cronograma da pesquisa

6. Bibliografia

Resumo

Este trabalho propõe o desenvolvimento e a avaliação de modelos de classificação de tumores cerebrais em imagens de ressonância magnética utilizando transferência de aprendizado, nas classes glioma, meningioma, tumor hipofisário e ausência de tumor. Serão comparadas as arquiteturas ResNet50, EfficientNet-B0 e MobileNetV3 quanto ao desempenho preditivo e à eficiência computacional. Antes do treinamento, a base pública será submetida a uma auditoria de deduplicação, com identificação de arquivos exatamente iguais e de imagens visualmente semelhantes, avaliando-se o impacto dessa etapa sobre as métricas obtidas — um cuidado metodológico frequentemente ausente em trabalhos que utilizam a mesma base. Os modelos serão avaliados por acurácia, Macro F1-Score, AUC-ROC one-vs-rest e matriz de confusão, além de parâmetros, tamanho e tempo de inferência. Para análise exploratória da interpretabilidade, será empregado o Grad-CAM. Espera-se identificar o efeito da deduplicação sobre o desempenho e determinar qual arquitetura oferece o melhor equilíbrio entre capacidade de classificação e custo computacional. O estudo possui finalidade acadêmica e não pretende validar uma ferramenta para diagnóstico clínico.

Palavras-chave: tumores cerebrais; ressonância magnética; aprendizado profundo; transferência de aprendizado; redes neurais convolucionais.

1. Problemática

Os tumores cerebrais constituem um grupo de alterações caracterizadas pelo crescimento anormal de células no cérebro ou em estruturas próximas. A ressonância magnética destaca-se na investigação dessas alterações por produzir imagens detalhadas dos tecidos cerebrais, e a análise desses exames requer conhecimento especializado, podendo envolver grande quantidade de imagens. Nesse contexto, técnicas de aprendizado profundo vêm sendo investigadas como instrumentos de apoio à análise de imagens médicas. Redes neurais convolucionais aprendem automaticamente características visuais relevantes, mas seu treinamento completo geralmente demanda grandes conjuntos de dados; a transferência de aprendizado permite adaptar modelos previamente treinados para uma tarefa específica, reduzindo parte dessa demanda.

O tema deste projeto é delimitado à classificação multiclasse de imagens bidimensionais de ressonância magnética cerebral nas categorias glioma, meningioma, tumor hipofisário e ausência de tumor, comparando-se as arquiteturas ResNet50, EfficientNet-B0 e MobileNetV3, previamente treinadas no ImageNet. O trabalho avaliará desempenho preditivo, custo computacional, impacto da remoção de imagens duplicadas ou visualmente semelhantes e interpretabilidade por Grad-CAM. O sistema terá finalidade exclusivamente acadêmica e experimental, sem pretensão de diagnóstico ou validação clínica.

Resultados elevados em bases públicas devem ser interpretados com cautela. Duplicatas, versões modificadas da mesma imagem ou cortes do mesmo paciente distribuídos entre treinamento e teste podem causar vazamento de dados, e a acurácia isolada não descreve adequadamente o comportamento de um classificador médico multiclasse. Diante disso, formula-se o seguinte **problema de pesquisa**: como a deduplicação da base e a escolha da arquitetura de transferência de aprendizado influenciam o desempenho, a eficiência computacional e a interpretabilidade de modelos para classificação de tumores cerebrais em imagens de ressonância magnética?

A **questão principal** que orienta a investigação é: qual das arquiteturas ResNet50, EfficientNet-B0 e MobileNetV3 apresenta o melhor equilíbrio entre desempenho de classificação, eficiência computacional e interpretabilidade? Como questões secundárias, investiga-se:

- A remoção de imagens duplicadas ou altamente similares modifica significativamente o desempenho?
- Qual arquitetura apresenta o melhor Macro F1-Score?
- Quais classes apresentam maior frequência de confusão?
- Modelos compactos mantêm desempenho competitivo em relação a modelos maiores?
- As regiões destacadas pelo Grad-CAM são visualmente coerentes com as áreas relevantes?

Como **hipótese principal**, espera-se que a transferência de aprendizado permita alcançar desempenho satisfatório na classificação multiclasse, mesmo com uma base de tamanho limitado. Complementarmente:

- **H1:** a remoção de imagens duplicadas ou altamente similares reduzirá métricas artificialmente elevadas.
- **H2:** existirá um trade-off claro entre desempenho e custo computacional entre as três arquiteturas — com a EfficientNet-B0 tendendo ao melhor equilíbrio geral, a ResNet50 apresentando desempenho competitivo com maior custo, e a MobileNetV3 mantendo desempenho próximo às demais com menor tamanho e tempo de inferência.
- **H3:** o aumento de dados aplicado somente ao treinamento contribuirá para diminuir o sobreajuste.
- **H4:** o Grad-CAM ajudará a identificar decisões baseadas em regiões irrelevantes ou artefatos.

As hipóteses serão confirmadas ou rejeitadas com base nos experimentos; não se pressupõe antecipadamente a superioridade de um modelo.

Um levantamento preliminar da literatura mostra que a base de dados a ser utilizada ("Brain Tumor MRI Dataset", ver seção 4) já foi empregada em diversos estudos recentes de classificação por transferência de aprendizado, com resultados que vão de 98,73% de acurácia ponderada (DISCI; GURCAN; SOYLU, 2025) a 99,96% de acurácia com validação cruzada (RASA et al., 2024) — números elevados que reforçam a necessidade de verificar se parte desse desempenho decorre de vazamento de dados entre treino e teste. Essa preocupação é sustentada por Yagis et al. (2021), que demonstraram quantitativamente que a divisão de dados de ressonância magnética em nível de fatia 2D pode inflar artificialmente a acurácia em até 55% em bases neurológicas. Precedente direto é dado por Fateh et al. (2026), que, ao construir um novo dataset a partir da mesma base pública aqui utilizada, reportaram a remoção de duplicatas exatas e quase-duplicatas antes da divisão treino/teste como etapa necessária para evitar vazamento e sobre-representação. Não foram encontrados, até o momento, trabalhos que apliquem essa auditoria diretamente sobre a base original combinada às três arquiteturas propostas, o que caracteriza a lacuna de pesquisa que este projeto pretende explorar.

2. Justificativa

Razões de ordem teórica: a aplicação de aprendizado profundo em imagens médicas possui relevância científica e tecnológica, mas resultados confiáveis exigem metodologia que considere qualidade dos dados, risco de vazamento e comportamento por classe, não somente acurácia final. A auditoria de duplicatas constitui o principal diferencial metodológico deste trabalho: ela

pode revelar quanto o vazamento de dados influencia as métricas em uma base amplamente utilizada por trabalhos semelhantes, muitos dos quais reportam desempenho elevado sem essa verificação (ver seção 1).

Razões de ordem social: tumores cerebrais afetam pacientes de todas as faixas etárias e seu diagnóstico precoce está diretamente relacionado a melhores taxas de sobrevivência. Ainda que o presente estudo não pretenda validar uma ferramenta clínica, ele contribui para o campo de apoio computacional ao diagnóstico por imagem, disseminando conhecimento sobre um tópico de grande relevância para a saúde pública, com potencial benefício indireto a um número expressivo de pacientes ao longo do tempo, caso a linha de pesquisa avance para etapas de validação clínica em trabalhos futuros.

Razões de ordem tecnológica: a disponibilidade de bases públicas torna a classificação de tumores cerebrais um problema viável para investigar visão computacional e transferência de aprendizado sem coleta clínica direta. A comparação entre redes com características distintas permitirá estudar a relação entre capacidade preditiva e custo computacional, produzindo um pipeline reprodutível — incluindo auditoria de dados, treinamento e explicabilidade — que poderá ser replicado ou adaptado por outros pesquisadores e profissionais da área.

3. Objetivos

3.1. Objetivo geral

Desenvolver e avaliar modelos de classificação de tumores cerebrais em imagens de ressonância magnética utilizando transferência de aprendizado, comparando desempenho preditivo, eficiência computacional, influência da deduplicação e explicabilidade.

3.2. Objetivos específicos

- Selecionar e documentar uma base pública de ressonâncias magnéticas.
- Analisar distribuição, origem, licença, formatos e qualidade das imagens.
- Detectar duplicatas exatas por hash criptográfico e similares por hash perceptual.
- Definir divisões de treinamento, validação e teste sem vazamento conhecido.
- Implementar uma CNN simples como baseline.
- Aplicar ResNet50, EfficientNet-B0 e MobileNetV3 com transferência de aprendizado.
- Comparar métricas preditivas e computacionais entre os modelos, com e sem deduplicação.
- Analisar erros e matrizes de confusão por classe.
- Aplicar Grad-CAM e discutir limitações, vieses e generalização dos modelos.

4. Metodologia

A pesquisa será aplicada, quantitativa, experimental e exploratória. O desempenho dos classificadores será avaliado numericamente em condições controladas, seguindo as etapas descritas a seguir.

Base de dados

Será utilizada a base pública "Brain Tumor MRI Dataset", disponibilizada por Masoud Nickparvar na plataforma Kaggle (NICKPARVAR, 2021), contendo as quatro classes definidas (glioma, meningioma, tumor hipofisário e ausência de tumor). Antes de sua utilização, serão registrados quantidade por classe, formato, resolução, licença, identificadores disponíveis e fontes primárias que compõem a base. O Kaggle será tratado como plataforma de redistribuição, buscando-se citar a origem original sempre que possível. Serão incluídas imagens das classes definidas, com arquivos legíveis, rótulos válidos e licença compatível; serão excluídos ou analisados separadamente arquivos corrompidos, rótulos ausentes ou ambíguos, duplicatas confirmadas e arquivos com origem ou permissão inadequada.

Auditoria, deduplicação e divisão dos dados

A auditoria ocorrerá antes da divisão dos dados. SHA-256 identificará arquivos exatamente iguais; pHash ou dHash, com distância de Hamming, sinalizará similaridade visual. Pares serão registrados, agrupados e inspecionados por amostragem, sem exclusão automática de imagens semelhantes, pois podem representar cortes distintos de um mesmo exame. A divisão dos dados será feita, preferencialmente, por paciente, em 70% para treinamento, 15% para validação e 15% para teste; na ausência de identificadores, será usada divisão estratificada, com a limitação explicitada. Um mesmo grupo de duplicatas ficará em uma única partição, e o teste permanecerá isolado até a definição final.

Pré-processamento, modelos e treinamento

O pipeline incluirá conversão de canais quando necessária, redimensionamento com preservação de proporção, normalização específica do modelo e padronização das classes. O aumento de dados será aplicado como prática padrão, restrita ao treinamento, podendo incluir pequenas rotações, translações, zoom e ajustes leves de brilho ou contraste. Uma CNN simples servirá como baseline. Nas redes pré-treinadas, inicialmente serão congelados os extratores de características e treinada a nova cabeça de classificação; em seguida, poderá ser feito fine-tuning parcial com taxa de aprendizado menor, mantendo-se condições equivalentes de divisão, transformações, épocas, early stopping e seleção de checkpoint entre os experimentos.

Plano experimental e métricas

O plano experimental compreende sete experimentos centrais: E1 e E2 avaliam, respectivamente, a CNN baseline e um modelo pré-treinado sobre a base sem deduplicação, como referência de possível inflação de métricas; E3 repete a CNN baseline já sobre a base deduplicada; E4, E5 e E6 aplicam ResNet50, EfficientNet-B0 e MobileNetV3, respectivamente, também sobre a base deduplicada, como avaliação principal; e E7 aplica Grad-CAM e análise de erros sobre o melhor modelo identificado. Serão calculadas acurácia, precisão, sensibilidade, especificidade e F1 por classe, Macro F1, Macro AUC, AUC-ROC one-vs-rest e matriz de confusão, além de parâmetros totais e treináveis, tamanho em MB e tempo de inferência como medidas computacionais.

Explicabilidade

O Grad-CAM (SELVARAJU et al., 2017) será aplicado a uma amostra representativa de acertos de alta confiança e aos erros mais frequentes identificados na matriz de confusão, com interpretação exploratória das regiões associadas às decisões dos modelos.

Tecnologias e ferramentas

Categoria	Ferramentas possíveis
Linguagem e IA	Python; PyTorch ou TensorFlow/Keras; scikit-learn
Imagem e dados	OpenCV; Pillow; ImageHash; NumPy; Pandas
Visualização	Matplotlib; Seaborn
Ambiente	Jupyter; Google Colab; Kaggle
Versionamento	Git e GitHub

Será escolhido apenas um framework principal de aprendizado profundo, conforme a experiência da equipe. Testes estatísticos formais (múltiplas sementes, bootstrap, teste de McNemar), medição de FLOPs/MACs e validação externa em outra base pública são tratados como extensões do escopo central, a serem incorporadas apenas se o cronograma permitir.

5. Cronograma da pesquisa

Cronograma indicativo para dez meses, a ser preenchido e ajustado em conjunto com o orientador conforme o calendário da instituição.

Atividade	1	2	3	4	5	6	7	8	9	10
Tema e problema										
Revisão bibliográfica										
Base e documentação										
Auditoria/deduplicação										
Pré-processamento										
Baseline										
Treinamento (E1-E6)										
Ajustes										
Avaliação										
Grad-CAM (E7)										
Extensões (se houver tempo)										
Redação										
Revisão/apresentação										

6. Bibliografia

Bibliografia principal

DISCI, Rukiye; GURCAN, Fatih; SOYLU, Ahmet. Advanced brain tumor classification in MR images using transfer learning and pre-trained deep CNN models. *Cancers*, v. 17, n. 1, p. 121, 2025. DOI: 10.3390/cancers17010121.

FATEH, Amirreza; REZVANI, Yasin; MOAYEDI, Sara; REZVANI, Sadjad; FATEH, Fatemeh; FATEH, Mansoor; ABOLGHASEMI, Vahid. BRISC: annotated dataset for brain tumor segmentation and classification. *Scientific Data*, 2026. DOI: 10.1038/s41597-026-06753-y.

HE, Kaiming; ZHANG, Xiangyu; REN, Shaoqing; SUN, Jian. Deep residual learning for image recognition. In: IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (CVPR), 2016, Las Vegas. *Proceedings* [...]. Piscataway: IEEE, 2016. p. 770-778.

HOWARD, Andrew; SANDLER, Mark; CHU, Grace; CHEN, Liang-Chieh; CHEN, Bo; TAN, Mingxing; WANG, Weijun; ZHU, Yukun; PANG, Ruoming; VASUDEVAN, Vijay; LE, Quoc V.; ADAM, Hartwig. Searching for MobileNetV3. In: IEEE/CVF INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), 2019, Seoul. *Proceedings* [...]. Piscataway: IEEE, 2019. p. 1314-1324.

NICKPARVAR, Masoud. *Brain Tumor MRI Dataset*. Kaggle, 2021. Disponível em: <https://www.kaggle.com/datasets/masoudnickparvar/brain-tumor-mri-dataset>. Acesso em: 24 ago. 2026.

SELVARAJU, Ramprasaath R.; COGSWELL, Michael; DAS, Abhishek; VEDANTAM, Ramakrishna; PARIKH, Devi; BATRA, Dhruv. Grad-CAM: visual explanations from deep networks via gradient-based localization. In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION (ICCV), 2017, Venice. *Proceedings* [...]. Piscataway: IEEE, 2017. p. 618-626.

TAN, Mingxing; LE, Quoc V. EfficientNet: rethinking model scaling for convolutional neural networks. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 36., 2019, Long Beach. *Proceedings* [...]. [S.l.]: PMLR, 2019. p. 6105-6114.

YAGIS, Ekin; ATNAFU, Selamawet Workalemahu; GARCÍA SECO DE HERRERA, Alba; MARZI, Chiara; SCHEDA, Riccardo; GIANNELLI, Marco; TESSA, Carlo; CITI, Luca; DICIOTTI, Stefano. Effect of data leakage in brain MRI classification using 2D convolutional neural networks. *Scientific Reports*, v. 11, n. 22544, 2021. DOI: 10.1038/s41598-021-01681-w.

Bibliografia complementar

RASA, Sadia Maduri; ISLAM, Md. Manowarul; TALUKDER, Md. Alamin; UDDIN, Md. Ashraf; KHALID, Majdi; KAZI, Mohsin; KAZI, Md. Zobayer. Brain tumor classification using fine-tuned transfer learning models on magnetic resonance imaging (MRI) images. *Digital Health*, v. 10, 2024. DOI: 10.1177/20552076241286140.

Nota: esta bibliografia cobre as fontes já consultadas na elaboração deste pré-projeto. A revisão de literatura será ampliada ao longo do desenvolvimento do TCC.